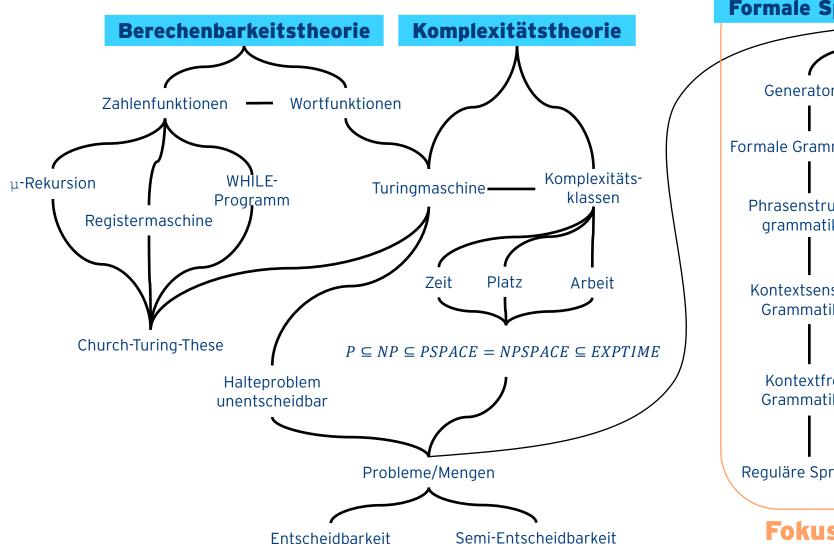


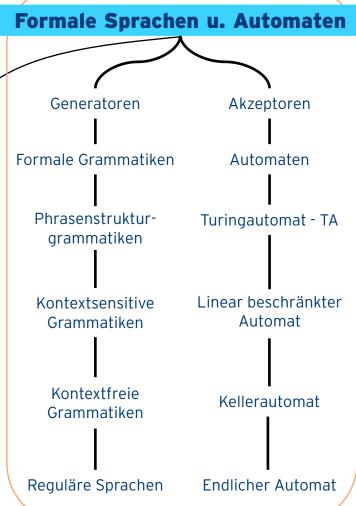
Agenda

- **01** Alphabete
- **02** Wörter
- Formale Sprachen



Theoretische Informatik - Themenübersicht





Fragestellung

Was versteht man unter einer formalen Sprache?



Aufbau formaler Sprachen

Folgende Konvention gilt dabei aus Perspektive der formalen Sprachen:

Sprache: Menge von Zeichenreihen aus Eingabezeichen

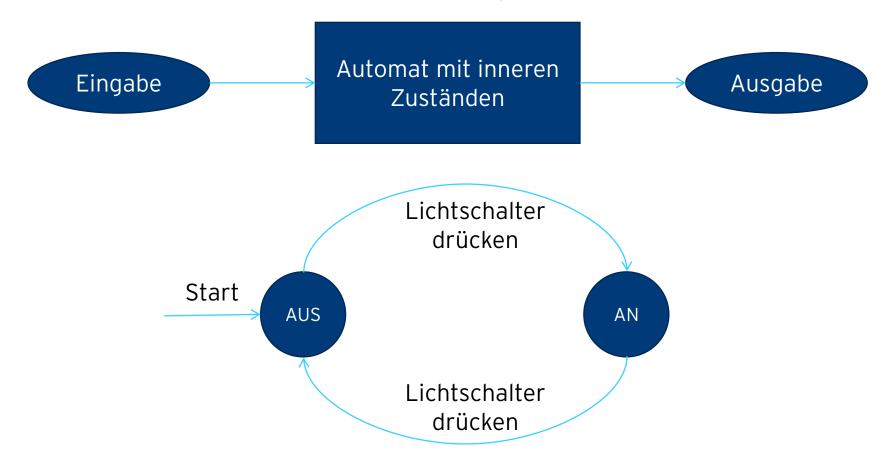
- Menge der Zeichenreihen einer natürlichen Sprache
- Menge aller von einem endlichen Automaten akzeptierten Zeichenreihen

Zeichenreihe: Reihe aus Elementen eines Alphabets bspw. Nutzung als Eingabe- oder Ausgabesequenz endlicher Automaten

Alphabet: Endliche Menge unzerlegbarer Einzelzeichen/Symbole bspw. Nutzung als Eingabe- oder Ausgabe endlicher Automaten

Anwendungen formaler Sprachen

Wofür werden Zeichen, Zeichenketten und Sprachen benötigt?



Chomsky-Hierarchie formaler Sprachen

Formale Sprachen werden gemäß der Chomsky-Hierarchie klassifiziert.

Details dazu folgen später.



Kontextsensitive Sprachen - Typ 1 Grammatiken

Kontextfreie Sprachen - Typ 2 Grammatiken

Reguläre Sprachen - Typ 3 Grammatiken



Avram Noam Chomsky

Abschnitt 1

Alphabete

Alphabete

Definition:

Ein **Alphabet** Σ ist eine endliche, **abgeschlossene** Menge von vereinbarten, eindeutigen und unterscheidbaren Zeichen bzw. Symbolen.

Allgemeine Notation:

$$\Sigma = \{a_1, ..., a_m\}$$
 mit $a_i \neq a_j, i, j \in \mathbb{N} \land i \neq j$
 $0 \leq |\Sigma| < +\infty$

Beispiele:

- $\Sigma_1 = \{a_1, a_2, a_3\}$ mit $a_1 = lpha, a_2 = oldsymbol{eta}, a_3 = oldsymbol{\gamma}$
- $\Sigma_2 = \{a, b, c, d, e, f, ..., x, y, z\}$

Definition von Alphabeten (1)

Anmerkung:

- Alphabete lassen sich **extensional** mit Angabe ihrer Elemente darstellen, z.B. $\Sigma_3 = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$. Alternativ gilt auch eine suggestive Darstellung à la $\Sigma_3 = \{0, 1, 2, ..., 9\}$, sofern Eindeutigkeit besteht.
- Eleganter ist die **intensionale** Angabe einer eingrenzenden Eigenschaft $\xi(a_i)$, sofern eine Teilmengenbeziehung $\Sigma \subseteq A$ besteht, siehe nächste Folie.

Definition von Alphabeten (2)

Prinzip der Aussonderung:

Die Definition eines Alphabets mithilfe einer Eigenschaft $\xi(a_i)$ ist stets dann sinnvoll, falls die Elemente von Σ eine Teilmenge einer bestimmten Obermenge $A = \{a_1, ..., a_n\}$ darstellen.

So gilt allgemein:

$$\Sigma = \{a \in A | \xi(a)\}$$

Beispiel:

Gegeben sei die Obermenge \mathbb{N}^+ . So gilt für das Alphabet $\Sigma_4 = \{a \in \mathbb{N}^+ | \xi(a)\}$ mit $\xi(a) = a \mod 2 = 0 \land a < 10$: $\Sigma_4 = \{2, 4, 6, 8\}$

Für solche Alphabete gilt also:

$$\Sigma \subseteq A$$
 oder

 $\Sigma \in P(A)$ (Potenzmenge von A, vgl. Folie 15)

Kardinalität von Alphabeten

Falls

$$|\mathbf{\Sigma}|=\mathbf{0}$$
 ,

dann gilt

$$\Sigma = \emptyset$$
 ,

das heißt, das Alphabet $oldsymbol{arSigma}$ ist leer.

Lexikographische Ordnung auf Zeichen

Für die Darstellung der Elemente aus Σ bietet sich die Nutzung einer **lexikographischen Ordnung** $R \subseteq \Sigma \times \Sigma$ mit $R = \langle$ an:

$$a_i < a_{i+1} \dots < a_{n-1}$$
, $i, n \in I \subseteq \mathbb{N}$

Die mithilfe der Indexmenge I indizierten Elemente a_i werden anhand eines vereinbarten Kriteriums sortiert (Anmerkung: Es handelt sich um einzelne Zeichen a_i).

Beispiel Binäralphabet:

$$B = \{0, 1\}, a_1 = 0, a_2 = 1$$

Die **Relation** R ist **transitiv**, was ebenfalls für die Inverse R^{-1} bzw. > gilt.

$$a_iRa_{i+n}\wedge a_{i+n}Ra_{i+m}\Rightarrow a_iRa_{i+m}$$
 bzw. $a_i < a_{i+n}\wedge a_{i+n} < a_{i+m} \Rightarrow a_i < a_{i+m}$

Beispiel:

$$1R2 \land 2R5 \Rightarrow 1R5$$
 bzw. $1 < 2 \land 2 < 5 \Rightarrow 1 < 5$

Abgeschlossenheit von Alphabeten

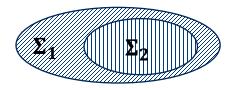
Aufgrund ihres Mengencharakters können Alphabete mit den üblichen Operationen behandelt werden.

Differenzmengenoperation:

$$\Sigma_1 \setminus \Sigma_2 = \Sigma_3$$

Vereinigungsoperation:

$$\Sigma_1 \cup \Sigma_2 = \Sigma_3$$



Schnittmengenbildung:

$$\Sigma_1 \cap \Sigma_2 = \Sigma_3$$

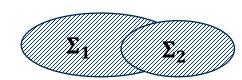
Symmetrische Differenz zweier Mengen:

$$\Sigma_1 \triangle \Sigma_2 = (\Sigma_1 \cup \Sigma_2) \setminus (\Sigma_1 \cap \Sigma_2)$$



$$|\Sigma_1 \triangle \Sigma_2| = 0 \Rightarrow \Sigma_1 = \Sigma_2$$

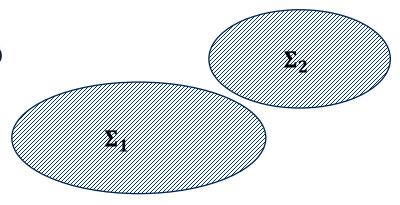
Wichtig: Alphabete sind abgeschlossen gegenüber Mengenoperationen.



Zeichenmengen

Weiterhin gilt:

$$|\Sigma_1 \cup \Sigma_2| = |\Sigma_1| + |\Sigma_2|$$
 gdw. $\Sigma_1 \cap \Sigma_2 = \emptyset$



Die Menge aller möglichen Teilmengen σ von Σ ergibt sich über das **Potenzmengenaxiom**:

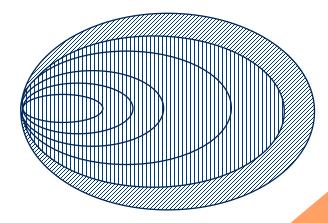
$$P(\Sigma) = {\sigma | \sigma \subseteq \Sigma}$$

Dabei gilt:

$$|P(\Sigma)| = 2^{|\Sigma|}$$

 $P(\Sigma = \emptyset) = \{\emptyset\}$

(Die Potenzmenge eines Alphabets ist nicht leer.)



Abschnitt 2

Wörter

Wörter

Wörter w (Zeichenketten, Strings) ergeben sich durch die Aneinanderreihung der Elemente aus Σ .

Beispiel:

$$w = abc$$
 mit $a, b, c \in \Sigma$

Formal wird die **Konkatenation** \circ einzelner Zeichen aus Σ über die Abbildung

$$\circ: \Sigma \times \Sigma \to \Sigma^*$$

beschrieben:

$$w = a \circ b \circ c$$

Dabei gilt:

$$\forall a \in \Sigma : \varepsilon \circ a = a \circ \varepsilon = a$$

D.h., das leere Wort ε (international auch: λ) ist das **Neutralelement der Verkettungsoperation**. Das leere Wort ε dient dabei als theoretisches Konstrukt, das für weiterführende Überlegungen von Belang ist.

Anmerkung:

Jedes Wort w lässt sich als Verkettung beliebiger Zeichen $a \in \Sigma$ mit dem leeren Wort ε in beliebiger Häufigkeit darstellen - z.B. $w = a_1 \varepsilon a_2 \varepsilon \varepsilon \varepsilon a_1 \varepsilon = a_1 a_2 a_1$. 17

Wörter - Konkatenation (1)

Die wiederholte Konkatenation eines Zeichens $a \in \Sigma$ mit sich selbst führt zur **Potenz eines Zeichens**: a^n

Beispiel: $a \circ a = a^2$

Analog zur Arithmetik gilt:

$$a^0 = \varepsilon \equiv x^0 = 1$$

Die rekursive Definition der Konkatenation lässt sich wie folgt ausdrücken:

$$a^{1} = a^{0} \circ a^{1} = a$$
 $a^{2} = a^{0} \circ a^{1} \circ a^{1} = a \circ a^{1} = a \circ (a^{0} \circ a^{1}) = aa$

D.h.,

$$a^{n+1}=a^n\circ a^1$$

Für die Verkettung unterschiedlicher Zeichen gelten dieselben Regeln und Notationen

$$a^{n+1}b^{n+1}=a^n\circ a^1\circ b^n\circ b^1$$

Potenzen unterschiedlicher Zeichen können konkateniert werden, z.B. $a^nb^{n+m}c^{n+t}$

Wörter - Konkatenation (2)

Beispiel:

$$\boldsymbol{\Sigma} = \{\boldsymbol{a}_1, \boldsymbol{a}_2, \boldsymbol{a}_3\}$$

mit

$$a_1 = \S, a_2 = !, a_3 = \S$$

So ergibt sich mit

für das Wort w folgende Darstellung:

$$w = a_2^3 \circ a_1^5 \circ a_3^7 = \text{!!! }$$

Kleenesche Hülle

Die Potenzbildung eines Zeichens lässt sich auch auf Zeichenmengen übertragen:

$$\Sigma^0 = \{ \varepsilon \}$$

$$\Sigma^1=\Sigma\circ\Sigma^0=\{arepsilon a_1\ldotsarepsilon a_n\}=\{a_1\ldots a_n\},\ \mathrm{wenn}\ \Sigma=\{a_1,\ldots,a_n\}$$

$$\Sigma^2=\Sigma^1\circ\Sigma^1=\{a_1a_1\ldots a_na_n\}$$

$$\Sigma^3=\Sigma\circ\Sigma^2=\{a_1a_1a_1\ldots a_na_na_n\}$$

$$\Sigma^n=\Sigma^{n-1}\circ\Sigma=\{\ldots\}$$

Die Vereinigung aller Potenzen über Σ bildet den Kleene-Abschluss (Kleenesche Hülle, Sternhülle):

$$\Sigma^* = \bigcup_{n=0}^{\infty} \Sigma^n$$

Für die Menge aller Wörter (**Plushülle**) ohne das leere Wort gilt:

$$\Sigma^* \setminus \{ oldsymbol{arepsilon} \} = \Sigma^+$$

Wichtig:

$$\{\boldsymbol{\varepsilon}\}\neq\emptyset$$

Wortoperationen - Konkatenation

Die Konkatenation lässt sich auch auf Elemente $w \in \Sigma^*$ anwenden.

$$w_3 = w_1 \circ w_2$$

Beispiel: mit $w_1 = \S^5$ und $w_2 = !^2$ ist $w_3 = w_1 \circ w_2 = \S^5 \circ !^2$

Auch gilt hier

$$w_3^0 = \varepsilon$$

bzw.

$$\forall w \in \Sigma^* : w^0 = \varepsilon$$

Somit bildet die algebraische Struktur (Σ^* , \circ) ein **Monoid** bzw. eine Halbgruppe **mit einem Neutralelement**, da

- Innere zweistellige Verknüpfung: $\circ: \Sigma^* \times \Sigma^* \to \Sigma^*$
- Assoziativität der Operation: $\forall a,b,c \in \Sigma^*$: $(a \circ b) \circ c = a \circ (b \circ c)$
- Neutralelement: $a \circ \varepsilon = a$

Wörter - Ordnung (1)

Analog zur Darstellung von Σ unterliegen auch die Elemente von Σ^* einer **lexikographischen Ordnung** \prec :

$$\prec \subseteq \Sigma^* \times \Sigma^*$$

So gilt für die Elemente $v, w \in \Sigma^*$

$$v=v_{i=1}\dots v_{i=m},\ v_i\in \Sigma, 1\leq i\leq m, \qquad w=w_{j=1}\dots w_{j=n}, w_j\in \Sigma, 1\leq j\leq n$$

$$v\prec w \text{ bzw. } (v,w)\in \prec$$

genau dann, wenn

D.h., die Sortierung erfolgt gemäß der Länge der Wörter.

Beispiel für $L \subseteq \Sigma^*$ mit $\Sigma = \{a\}$:

$$\prec_{\Sigma^*} = \{(a, aa), (a, aaa), \dots, (aa, aaa), \dots, (aaa, aaaa), \dots\}$$

$$L = \{a, aa, aaa, aaaa\}$$

Die Relation \prec_{Σ^*} ist ebenfalls transitiv.

Wörter - Ordnung (2)

Ferner gilt für die Elemente $v, w \in \Sigma^*$

$$v=v_1\dots v_m,\ v_i\in \Sigma, 1\leq i\leq m,\qquad w=w_1\dots w_n, w_j\in \Sigma, 1\leq j\leq n$$

$$v\prec w \text{ bzw. } (v,w)\in \prec \text{genau dann,}$$

falls m=n=1 und $v_1 \prec w_1$ oder

m = n > 1 und es ein k gibt, welches folgende Kriterien erfüllt:

$$1 \le k < m$$

und

$$v_1 ... v_k = w_1 ... w_k$$
 und $v_{k+1} < w_{k+1}$

Das heißt, Wörter $w \in L$ gleicher Länge werden **stellenwertig** hinsichtlich der enthaltenen Alphabetzeichen $a, b \in \Sigma$ sortiert.

Beispiel:

$$\mathbf{\Sigma} = \{\mathbf{d}, \mathbf{e}\}$$

 $L = \{d, e, dd, de, ed, ee, ddd, \dots\}$

Als Alternative gibt es die bekannte **lexikalische Ordnung** (wie im Lexikon): Wörter werden unabhängig von ihrer Länge nach alphabetischer Reihenfolge sortiert.

Wortoperationen - Länge

Die Länge eines Wortes w lässt sich mit der rekursiv definierten Funktion len bestimmen:

$$len: \Sigma^* \to \mathbb{N}_0$$
 $len(aw) = len(w) + 1, a \in \Sigma, w \in \Sigma^*$

Dabei gilt:

$$len(\varepsilon) = 0$$

Beispiel:

$$w = abc$$
 $len(abc) = len(bc) + 1 = len(c) + 1 + 1 = len(\varepsilon) + 1 + 1 + 1 = 0 + 1 + 1 + 1$ $len(abc) = 3$

Zeichenketten/Wörter/Strings werden sequentiell abgearbeitet.

Alternativ:

Die Länge eines Wortes w kann auch über die Nutzung von Betragsstrichen |w| angezeigt werden.

Wörter - Prä-, In- und Suffix (1)

Aufbau eines Wortes/Strings w:

$$(w \in \Sigma^*) \land (w = xyz; x, y, z \in \Sigma^*)$$

Dabei ist x das **Präfix** des Wortes, y das **Infix** des Wortes und z das **Suffix** des Wortes w. Infixe, Suffixe und Präfixe sind als Worte w Elemente des Kleene-Stern-Produkts über Σ .

x ist **echtes Präfix** von w, wenn gilt:

x ist Präfix von w und $x \neq w$.

Analog dazu gelten auch die Definitionen für **echte** Infixe und Suffixe.

Wörter - Prä-, In- und Suffix (2)

Sonderfälle:

- Falls $x = w \rightarrow (x = Pr\ddot{a}fix, x = Infix und x = Suffix)$
- Falls $w = xy \rightarrow (x = Pr\ddot{a}fix, (x = Infix), y = Suffix)$

Präfixfreiheit: Eine Sprache $L \subseteq \Sigma^*$ heißt **präfixfrei**, falls

$$\forall w \in L : w = xyz \land x \notin L$$

Beispiele:

- $L_1=\{a^nb^n|n\geq 1\}$ Sprache L_1 ist präfixfrei, da für alle echten Präfixe a^nb^i für Elemente w aus L_1 mit n>i gilt: $a^nb^i\notin L_1$.
- $L_2=\{w\in\{a,b\}^*||w|_a=|w|_b\}$ Sprache L_2 hingegen enthält echte Präfixe (w=ababab, Präfix=ab).

Allgemein gilt, falls $\varepsilon \notin L$:

$$L \cap \{L \circ \Sigma^+\} = \emptyset$$

Wörter - Teilwörter (1)

Indizierung von Einzelzeichen:

Will man einzelne Zeichen eines Wortes w anzeigen oder Teilstrings s des Wortes, bietet sich die Verwendung eines Laufindex i an.

$$w = w_{i=1}w_{i=2}w_{i=3},...,w_{i=n}$$

Beispiel:

$$w = abbabba$$
 $w_3 = b$
 $w_{2:5} = bbab$

Möchte man anzeigen, dass ein wiederkehrendes Element gemeint ist (z. B. jedes zweite oder dritte Element des Wortes w), lässt sich folgende Notation verwenden:

$$w_{i \, mod \, j=0} = a \in \Sigma$$

Beispiel:

$$\Sigma = \{a, b, c, d\}, L \subseteq \Sigma^+, L = \{w \in \Sigma^+ | w_{i \, mod \, 2=0} = d\} = \{a, b, c, d, ad, bd, cd, dd, ..., adad, ...\}$$

Wörter - Teilwörter (2)

Finden eines Substring:

 $substr: \Sigma^* \times \Sigma^* \rightarrow \{ja, nein\}$

mit

 $substr(w,v) = \begin{cases} ja, falls \ v \ Infix \ von \ w \\ nein, sonst \end{cases}$

Beispiel:

w = aaabbbccc substr(w, bbb) = ja substr(w, aba) = nein

```
String w = "Haustuer";
String s = "tu";
boolean sIsInfixOfW = w.contains(s);
```

Wörter - Teilwörter (3)

Ausgeben eines Substring:

substr:
$$\Sigma^* \times \mathbb{N} \times \mathbb{N} \to \Sigma^*$$

mit

$$substr(w,i,j) = egin{cases} w_i & ... w_j, ext{falls } i \leq j \ & arepsilon, ext{sonst} \end{cases}$$
 für $w = w_1 \dots w_n$, $1 \leq i \leq n, 1 \leq j \leq n.$

Beispiel:

$$w = aabaaabbb, substr(w, 3, 7) = baaab$$

```
String w = "Haustuer";
String s = w.substring(0, 4); // Achtung: Index des ersten Zeichens ist O.
System.out.print(s); // Erster Index inklusive, zweiter exklusive
```

Wörter -Teilwörtern (4)

Zählen von Elementen in w:

$$anz: \Sigma^* \times \Sigma \to \mathbb{N}_0$$

Mit

$$anz(aw,b) = \begin{cases} anz(w,b) + 1, a = b \\ anz(w,b), a \neq b \end{cases}$$

Ferner gilt:

$$\forall b \in \Sigma : anz(\varepsilon, b) = 0$$

Alternative Notation:

$$anz(w,a) = |w|_a$$

Beispiel: w = aabccaac

$$anz(w,c) = anz(abccaac,c) = anz(bccaac,c) = anz(ccaac,c) = anz(caac,c) + 1 = anz(aac,c) + 1 + 1$$

= $anz(ac,c) + 1 + 1 = anz(c,c) + 1 + 1 = anz(c,c) + 1 + 1 + 1 = 0 + 1 + 1 + 1 = 3$

```
String w = "Haustueren"; int numOfChars = 0;
for (int i = 0; i < w.length(); i++)
    if (w.charAt (i) == 'e') numOfChars++;
System.out.print (numOfChars);</pre>
```

Wörter - Modifikation

Austauschen von Symbolen im String:

tausche: $\Sigma^* \times \Sigma \times \Sigma \rightarrow \Sigma^*$

Definiert wird die Funktion mittels:

$$tausche(aw, b, c) = \begin{cases} b \circ tausche(w, b, c), a = c \\ a \circ tausche(w, b, c), a \neq c \end{cases}$$

Ferner gilt:

$$tausche(\varepsilon, b, c) = \varepsilon$$

```
String w = "Haustueren";
w = w.replaceAll("a", "e"); // Achtung: Parameter in umgekehrter Reihenfolge
System.out.print(w);
```

Abschnitt 3

Formale Sprachen

Formale Sprachen

Eine Teilmenge von Σ^* wird als **formale Sprache** L über Σ bezeichnet, $L \subseteq \Sigma^*$

Beispiel:

$$\Sigma = \{a, b\}$$

$$\Sigma^* = \{\varepsilon, a, b, aa, ab, ba, bb, aaa\}$$

$$L = \{\varepsilon, a, b, aa, ab, ba, bb, aaa\}$$

Sprachen $m{L}$ können mit den üblichen Methoden der Mengenlehre behandelt werden. So gelten z.B. auch

$$L_3 = L_1 \cup L_2$$

oder

$$L_3 = L_1 \cap L_2$$

oder

$$L_3 = L_1 \setminus L_2$$

oder

$$L_3 = L_1 \triangle L_2$$

Formale Sprachen - Konkatenation

Die Konkatenation der Sprachen L_i erfolgt über die Konkatenation der Elemente:

$$L_n \circ L_m = \{vw | v \in L_n, w \in L_m\}$$

Beispiel:

$$L_n = \{aa, ab\}$$
 $L_m = \{\epsilon, cc, da\}$
 $L_n \circ L_m = \{aa, ab, aacc, aada, abcc, abda\}$

Allgemein gilt:

$$L_n \subseteq L_n \circ L_m$$
 gdw. $arepsilon \in L_m$

Mehrfach wiederholte Konkatenationen über Sprachen L_i lassen sich als Potenzen ausdrücken:

$$L^0 = \{ \varepsilon \}$$

$$L^1 = L^1 \circ L^0 = L^1 = L$$

An dieser Stelle ist $\{\varepsilon\}$ das Neutralelement:

$$L \circ \{ \varepsilon \} = L$$

Formale Sprachen - Konkatenation

Allgemein gilt:

$$L^{n+1} = L^n \circ L^1 = L^n \circ L$$

Das Kleene-Stern-Produkt ist die Vereinigung aller Potenzen einer Sprache L über Σ :

$$L^* = \bigcup_{i=0}^{\infty} L^i$$

Unter Aussonderung der leeren Sprache $L = \{ \boldsymbol{\varepsilon} \}$ gilt

$$igcup_{i=0}^{\infty} L^iackslash \{oldsymbol{arepsilon}\} = L^+ \ orall L^i\colon L^i\subseteq L^*\subseteq \Sigma^*$$

Die Potenzmenge $P(\Sigma^*)$ ist somit gegenüber der Operation

$$\circ: P(\Sigma^*) \times P(\Sigma^*) \to P(\Sigma^*)$$

abgeschlossen ($L \in P(\Sigma^*)$).

Formale Sprachen - Spiegelung

Die **Spiegelung** von Elementen aus *L* lässt sich wie folgt formulieren:

$$mirr: \Sigma^* \to \Sigma^*$$

mit der Definition

$$mirr(aw) = mirr(w) \circ a, w \in \Sigma^*, a \in \Sigma$$

$$mirr(\varepsilon) = \varepsilon$$

Verallgemeinert auf Sprachen ergibt sich:

$$mirr: P(\Sigma^*) \rightarrow P(\Sigma^*)$$

Damit gilt:

$$mirr(L) = \{mirr(w) | w \in L\}$$



NORDAKADEMIE gAG Hochschule der Wirtschaft